


SuperComputação

Aula 6 – Funções Intrínsecas

2019 – Engenharia

Igor Montagner, Luciano Soares <igorsm1@insper.edu.br>

Single Instruction Multiple Data (SIMD)



- Processamento de itens de dados em conjunto
- Operações aritméticas básicas
- Operações comuns mais complexas

Funções intrínsecas

- Streaming SIMD Extensions (SSE) e Advanced Vector Extensions (AVX) podem ser executados através de funções intrínsecas em C.
- Exemplo:
 - Assembly ***vaddps***: soma dois operandos e coloca resultado em um terceiro.
 - Função intrínseca **`_mm256_add_ps()`** mapeia diretamente para o `vaddps`

Tipos de Dados

Tipo de Dado	Descrição
<code>__m128</code>	Vetor de 128-bit contendo 4 floats
<code>__m128d</code>	Vetor de 128-bit contendo 2 doubles
<code>__m128i</code>	Vetor de 128-bit contendo inteiros*
<code>__m256</code>	Vetor de 256-bit contendo 8 floats
<code>__m256d</code>	Vetor de 256-bit contendo 4 doubles
<code>__m256i</code>	Vetor de 256-bit contendo inteiros*

* `__m256i` pode conter 32 chars, 16 shorts, 8 ints, ou 4 longs, além de serem com ou sem sinal (signed ou unsigned).

SSE/AVX

Teste o seguinte código:

```
#include <x86intrin.h>
#include <iostream>

int main() {
    // Cria dois vetores
    __m256 evens = _mm256_set_ps(2.0,4.0,6.0,8.0,10.0,12.0,14.0,16.0);
    __m256 odds = _mm256_set_ps(1.0,3.0,5.0,7.0,9.0,11.0,13.0,15.0);

    // Calcula a diferença dos dois vetores
    __m256 result = _mm256_sub_ps(evens, odds);

    // Exibe o resultado da operação
    float* f = (float*)&result;
    for(int i=0; i<8; ++i) std::cout << f[i] << ' ';
    std::cout << std::endl;
}
```

Compile com: g++ -mavx avx.cpp -o avx

Saída: 1 1 1 1 1 1 1 1

Inicialização com escalares

Função	Descrição
_mm256_setzero_ps/pd	Retorna um vetor de floating-point preenchidos com zero
_mm256_setzero_si256	Retorna um vetor de integer preenchidos com zero
_mm256_set1_ps/pd	Preenche um vetor com um valor floating-point
_mm256_set1_epi8/epi16 _mm256_set1_epi32/epi64	Preenche um vetor com um valor integer
_mm256_set_ps/pd	Inicia o vetor com oito floats (ps) ou quatro doubles (pd)
_mm256_set_epi8/epi16 _mm256_set_epi32/epi64	Inicia o vetor com integers
_mm256_set_m128/m128d/ _mm256_set_m128i	Inicia um vetor de 256-bit com dois de 128-bit
_mm256_setr_ps/pd	Inicia o vetor com oito floats (ps) ou quatro doubles (pd) na ordem reversa
_mm256_setr_epi8/epi16 _mm256_setr_epi32/epi64	Inicia o vetor com integers na ordem reversa

Inicialização com valores em memória

Função	Descrição
<code>_mm256_load_ps/pd</code>	Carrega um vetor alinhado de floating-point de um endereço de memória
<code>_mm256_load_si256</code>	Carrega um vetor alinhado de integers de um endereço de memória
<code>_mm256_loadu_ps/pd</code>	Carrega um vetor não alinhado de floating-point de um endereço de memória
<code>_mm256_loadu_si256</code>	Carrega um vetor não alinhado de integers de um endereço de memória
<code>_mm_maskload_ps/pd</code> <code>_mm256_maskload_ps/pd</code>	Carrega porções de vetor floating-point de 128/256-bit de acordo com máscara

Cada função `_maskload_` aceita dois argumentos: um endereço de memória e um vetor de inteiros com o mesmo número de elementos que o vetor de saída. Para cada elemento no vetor de inteiros cujo bit mais significativo é um, o elemento correspondente no vetor retornado é carregado a partir da memória. Se o bit mais significativo no vetor inteiro for zero, o elemento correspondente no vetor retornado é definido como zero.

Exemplo

```
#include <x86intrin.h>
#include <iostream>

int main() {
    float int_array[8] = {100, 200, 300, 400, 500, 600, 700, 800};

    // Criando vetor de máscara
    __m256i mask = _mm256_setr_epi32(-20, -72, -48, -9, -100, 3, 5, 8);

    // Carregando dados de forma seletiva no vetor
    __m256 result = _mm256_maskload_ps(int_array, mask);

    // Exibindo o resultado da operação
    float* res = (float*)&result;
    for(int i=0; i<8; ++i) std::cout << res[i] << ' ';
    std::cout << std::endl;
}
```

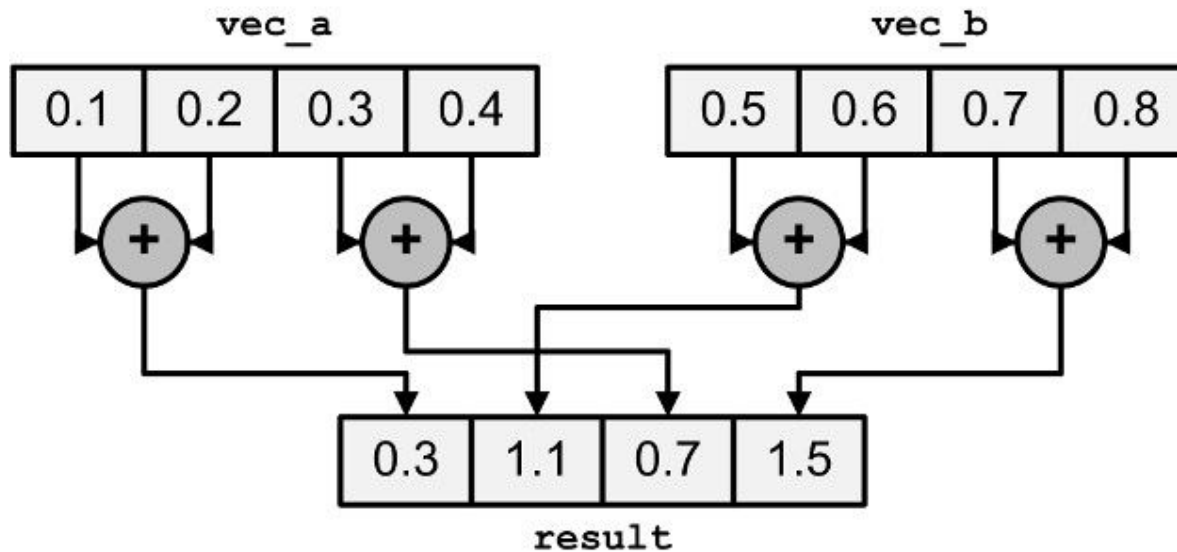
Saída: 100 200 300 400 500 0 0 0

Aritmética

Função	Descrição
_mm256_add_ps/pd	Soma dois vetores floating-point
_mm256_sub_ps/pd	Subtrai dois vetores floating-point
_mm256_hadd_ps/pd	Soma dois vetores floating-point horizontalmente
_mm256_hsub_ps/pd	Subtrai dois vetores floating-point horizontalmente
_mm256_addsub_ps/pd	Some e subtrai dois vetores floating-point
_mm256_mul_ps/pd	Multiplica dois vetores floating-point
_mm256_div_ps/pd	Divide dois vetores floating-point

Soma “Horizontal”

```
__m256d result = _mm256_hadd_pd(vec_a, vec_b);
```




Permutações e embaralhamento


Função	Descrição
<code>_mm_permute_ps/pd/ _mm256_permute_ps/pd</code>	Select elements from the input vector based on an 8-bit control value
<code>_mm256_permute2f128_ps /pd</code>	Select 128-bit chunks from two input vectors based on an 8-bit control value
<code>_mm256_permute2f128_si256</code>	Select 128-bit chunks from two input vectors based on an 8-bit control value
<code>_mm_permutevar_ps/pd _mm256_permutevar_ps/pd</code>	Select elements from the input vector based on bits in an integer vector
<code>_mm256_shuffle_ps/pd</code>	Select floating-point elements according to an 8-bit value
<code>_mm256_shuffle_epi8/ _mm256_shuffle_epi32</code>	Select integer elements according to an 8-bit value

Permutações e embaralhamento

```
res = _mm256_permute_ps(vec, 0b01110100)
```



```
res = _mm256_shuffle_ps(vec1, vec2, 0b01110100)
```



Auto vetorização

- A vectorização automática só ajuda em alguns casos
- A complexidade crescente das instruções dificulta para o compilador selecionar instruções apropriadas
- Código e lógica precisa ser reconhecido pelo compilador
- Os requisitos de precisão muitas vezes inibem o código SIMD

Auto vetorização

- Dependências de dados
- Outros motivos potenciais
 - Alinhamento
 - Chamadas de função no bloco de loop
 - Fluxo de controle complexo / ramos condicionais
 - Loop não "contabilizável"
 - E.g. tamanho do loop não é uma constante em tempo de execução
 - Tipos de dados misturados
 - Não possui espaçamento comum entre elementos de um vetor
 - Loop muito complexo
 - Vetorização parece ineficaz
- Muitos outros ... mas menos provável que ocorram

Auto vetorização

Suponha duas instruções S1 e S2

S2 depende do S1, se o S1 deve ser executado antes do S2

Dependência do fluxo de controle

Dependência de dados

Dependências podem ser transmitidas entre as iterações de loop

Principais sabores das dependências de dados

FLOW

s1: a = 40

b = 21

s2: c = a + 2



ANTI

b = 40

s1: a = b + 1

s2: b = 21



Atividade final

Implementação de soma_positivos usando intrínsecas

Referências

- Livros:

- Hager, G. ; Wellein, G. **Introduction to High Performance Computing for Scientists and Engineers**. 1ª Ed. CRC Press, 2010.

- Artigos:

- Firasta, Nadeem, Mark Buxton, Paula Jinbo, Kaveh Nasri, and Shihjong Kuo. "Intel AVX: New frontiers in performance improvements and energy efficiency." *Intel white paper* 19 (2008): 20.
- Jeong, Hwancheol, Sunghoon Kim, Weonjong Lee, and Seok-Ho Myung. "Performance of SSE and AVX instruction sets." *arXiv preprint arXiv:1211.0820* (2012).

- Internet:

- <https://monoinfinito.wordpress.com/series/vectorization-in-gcc/>
- <https://software.intel.com/en-us/articles/introduction-to-intel-advanced-vector-extensions>
- <https://software.intel.com/en-us/isa-extensions>
- <https://tech.io/playgrounds/283/sse-avx-vectorization/autovectorization>
- <https://software.intel.com/sites/landingpage/IntrinsicsGuide/>
- <https://www.codeproject.com/Articles/874396/Crunching-Numbers-with-AVX-and-AVX>

Inspire

www.inspire.edub.org